

第二部分 分布式算法

汪炆

中国科学技术大学计算机系
国家高性能计算中心（合肥）

Ch.1 导论

§ 1.1 分布式系统

- **Def:** 一个分布式系统是一个能彼此通信的单个计算装置的集合（计算单元：硬——处理器；软——进程）

包括：紧耦合系统----如共享内存多处理机

松散系统-----cow、Internet

- **与并行处理的分别**(具有更高层次的不确定性和行为的独立性)

- ❖ 并行处理的目标是使用所有处理器来执行一个大任务

- ❖ 而分布式系统中，每个处理器一般都有自己独立的任务，但由于各种原因（为共享资源，可用性和容错等），处理机之间需要协调彼此的动作。

- **分布式系统无处不在，其作用是：**

- ①共享资源

- ②改善性能：并行地解决问题

- ③改善可用性：提高可靠性，以防某些成分发生故障

§ 1.1 分布式系统

分布式系统软件实例简介

- **ElcomSoft Distributed Password Recovery**
是一款俄罗斯安全公司出品的分布式密码暴力破解工具
- 能够利用Nvidia显卡使WPA和WPA2无线密钥破解速度提高100倍
- 还允许数千台计算机联网进行分布式并行计算

§ 1.1 分布式系统

系统适用范围

- ElcomSoft 的密码恢复软件主要是面向 Office，包括（Word, Excel, Access, Outlook, Outlook Express, VBA, PowerPoint and Visio)
- 其他的面向微软的产品有（Project, Backup, Mail, Schedule+), archive products (including ZIP, RAR, ACE and ARJ files)等

§ 1.1 分布式系统


演示界面-支持的文件类型

All Supported Documents

- crypt() Password Hashes (*.crypt)
- Domain Cached Credentials (security; security)
- Intuit Quicken (*.qdf)
- MD5 Password Hashes (*.md5)
- Lotus Notes (*.id; admindata.xml)
- PWDUMP Password Hashes (*.pwdump; lmnt.ls)
- Microsoft Office (*.doc; *.dot; *.xls; *.xl)
- OpenDocument (*.odt; *.ott; *.odg; *.otg; *.
- Oracle Password Hashes (*.orc)
- Adobe PDF (*.pdf)
- Personal Information Exchange (*.pfx; *.p
- PGP (*.pgp; *.pgd; *.exe; *.skr; *.wde; secr
- SYSKEY (sam; system; sam.bak; system.bak; sa
- WPA-PSK Hashes and Handshakes (*.cap; *.w
- All Files (*.*)

§ 1.1 分布式系统

演示一主界面



§ 1.1 分布式系统

最终破解效果

■ DOC加密的文档，8位数字型密码小于1分钟即可成功解

The screenshot displays a software interface with a left-hand navigation menu and a main content area. The navigation menu includes icons and labels for 'Recovery', 'Agents', 'Connection', 'Alerts', and 'Cache And Log'. The main content area features a table with system information, a summary bar, and a statistics section.

host name	ip-address	benchmark	cpu	gpu	administration	version	time to live	status
PC-200901022324	127.0.0.1	?	-	-	locally	2.71.195	1 min.	working

total : 1, working : 1, free : 0, off hours : 0, not responded : 0, disabled : 0

	items processed	processor time usage
today :	34 714 930	00:02:12 (00.394 %)
yesterday :	432 631 514	00:27:05 (01.882 %)
this week :	1 010 694 308	0 d. 01:42:48 (02.106 %)
this month :	1 010 694 308	0 d. 01:42:48 (02.106 %)
this year :	1 010 694 308	0 d. 01:42:48 (00.208 %)
total :	1 010 694 308	0 d. 01:42:48 (37.710 %)

Reset Statistics

	cpu(s)	gpu(s)
active :	-	-

§ 1.1 分布式系统 Agents工作界面

The screenshot shows the 'Elcomsoft Distributed Agent' window. It has a blue title bar and a tabbed interface with 'About', 'General', 'Limitations', 'Interface', and 'Log'. The 'About' tab is active, displaying version information and a table of processing statistics.

Version 2.71 (build 195)
Copyright (C) 2002-2008 Elcomsoft Co. Ltd. All rights reserved.

	items processed	processor time usage
today :	34 714 930	00:02:12 (00.378 %)
yesterday :	432 631 514	00:27:05 (01.882 %)
this week :	1 010 694 308	0 d. 01:42:48 (02.096 %)
this month :	1 010 694 308	0 d. 01:42:48 (02.096 %)
this year :	1 010 694 308	0 d. 01:42:48 (00.208 %)
total :	1 010 694 308	0 d. 01:42:48 (36.229 %)

	cpu(s)	gpu(s)
active :	-	-

current speed : 0 items / second

waiting ☒ offline

§ 1.1 分布式系统

NASA SETI寻找外星人计划

- **SETI (搜寻外星智慧)** 是一个寻找地球外智慧生命的科学性实验计划，使用射电望远镜来监听太空中的窄频无线电信号。假设这些讯号中有些不是自然产生的，那么只要我们侦测到这些讯号就可以证明外星科技的存在。
- 射电望远镜讯号主要由噪声 (来自天体的发射源与接收者的电子干扰) 与像电视转播站、雷达和卫星等等的人工讯号所组成。现代的 Radio SETI 计划会分析这些数字信息。有更强大的运算能力就可以搜寻更广泛的频率范围以及提高灵敏度。因此，**Radio SETI 计划对运算能力的需求是永无止尽的。**
- 原来的 SETI 项目曾经使用望远镜旁专用的超级计算机来进行大量的数据分析。1995年，David Gedye 提议射电 **SETI 使用由全球联网的大量计算机所组成的虚拟超级计算机来进行计算**，并创建了 SETI@home 项目来实验这个想法。SETI@home 项目于1999年5月开始运行。

§ 1.1 分布式系统

NASA SETI寻找外星人计划

SETI@home - Windows Internet Explorer

http://setiathome.berkeley.edu/index.php

SETI@home Needs your Help

Donate to SETI@home

Click Here for More Information

SETI@home 是什么?

SETI@home 是一项利用全球联网的计算机共同搜寻地外文明 (SETI) 的科学实验计划。你可以通过运行一个免费程序下载并分析从射电望远镜传来的数据来加入这个项目。

参与

- 下载
- 帮助信息
- 邀请好友
- 捐助
- 移植与优化
- ... 更多

关于

- 关于 SETI@home
- 关于 Astropulse
- 科学报导
- 技术新闻
- 服务器状态
- 研究状态
- 赞助商
- ... 更多

社区

- 留言板
- 问题解答
- 用户档案
- 检索用户
- 团队
- 网站和 IRC
- 图片与音乐

您的帐户

- 您的帐户
- 参数设置
- 计算证书

统计信息

- 用户排名
- 主机排名
- 团队排名
- Top GPU models

站点搜索:

语言

开始计算

- 1 阅读我们的规定和政策
- 2 下载, 安装并运行 SETI@home 使用的 BOINC 软件。在程序提示输入网址时, 请输入 <http://setiathome.berkeley.edu>

如果您有问题希望得到解答或者需要其它帮助, 请通过 [BOINC 在线帮助系统](#)来联系我们的志愿者。

特别说明:

- 直接 SETI@home 项目 (即 SETI@home Classic) 的用户
- 使用命令行版本或早于 5.0 版本的客户端的用户。

参加其它基于 BOINC 的项目 - 在 SETI@home 暂时没有计算任务的时候, 您的计算机就不至于闲着了。

今日用户

David Missal

18:39:m a conservative who grew up watching Star Trek and Lost in Space

新闻

Network routing problems have been fixed

For the last few months, network routing issues have been interfering with the connectivity of some participants. The actual problem turned out to be a lack of sufficient memory in our router at the [PAIX](#) in Palo Alto. Two days ago we increased the memory in that router by a factor of four. This fixed the problem.

We would like to thank [Hurricane Electric](#), [Packet Clearing House](#), and [CENIC](#) for their great technical help in diagnosing and fixing this problem.

21 Oct 2011 | 17:50:51 UTC · [评论](#)

Fall Funding Drive

Our annual fall funding drive has started. If you haven't gotten our message in your email, you can see it [here](#). Please help us keep SETI@home going by [donating today](#).

9 Oct 2011 | 18:27:45 UTC · [评论](#)

Another way to support SETI@home

In addition to crunching, you can provide some support to SETI@home by using [GoodSearch](#) and [GoodShop](#). These search engines redirect a half their advertising to revenues to charity. Just be sure to choose "University of California - SETI@home" as your charity of choice.

12 Sep 2011 | 20:38:21 UTC · [评论](#)

more data on the way

Internet | 保护模式: 禁用

20:19

2011/10/28

§ 1.1 分布式系统

■ 分布式系统面临的困难

❖ **异质性**：软硬件环境

❖ **异步性**：事件发生的绝对、甚至相对时间不可能总是精确地知道

❖ **局部性**：每个计算实体只有全局情况的一个局部视图

❖ **故障**：各计算实体会独立地出故障，影响其他计算实体的工作。

§ 1.2 分布式计算的理论

■ **目标：** 针对分布式系统完成类似于顺序式计算中对算法的研究

❖ **具体：** 对各种分布式情况发生的问题进行抽象，精确地陈述这些问题，设计和分析有效算法解决这些问题，证明这些算法的最优性。

■ **计算模型：**

❖ **通信：** 计算实体间msg传递还是共享变量？

❖ 哪些计时信息和行为是可用的？

❖ 容许哪些错误

■ **复杂性度量标准**

❖ 时间，空间

❖ 通信成本：msg的个数，共享变量的大小及个数

❖ 故障和非故障的数目

§ 1.2 分布式计算的理论

■ 否定结果、下界和不可能的结果

常常要证明在一个特定的分布式系统中，某个特定问题的不可解性。

就像NP-完全问题一样，表示我们不应该总花精力去求解这些问题。

当然，可以改变规则，在一种较弱的情况下去求解问题。

■ 我们侧重研究：

❖ 可计算性：问题是否可解？

❖ 计算复杂性：求解问题的代价是什么？

§ 1.3 理论和实际之关系

主要的分布式系统的种类，分布式计算理论中常用的形式模型之间的关系

■ 种类

- ❖ **支持多任务的OS**：互斥，死锁检测和防止等技术在分布式系统中同样存在。
- ❖ **MIMD机器**：紧耦合系统，它由分离的硬件运行共同的软件构成。
- ❖ **更松散的分布式系统**：由网络（局域、广域等）连接起来的自治主机构成

特点是由分离的硬件运行分离的软件。实体间通过诸如TCP/IP栈、CORBA或某些其它组件或中间件等接口互相作用。

§ 1.3 理论和实际之关系

■ 模型

模型太多。这里主要考虑三种，基于通信介质和同步程度考虑。

① **异步共享存储模型**：用于紧耦合机器，通常情况下各处理机的时钟信号不是来源于同一信号源

② **异步msg传递模型**：用于松散耦合机器及广域网

③ **同步msg传递模型**：这是一个理想的msg传递系统。该系统中，某些计时信息（如msg延迟上界）是已知的，系统的执行划分为轮执行，是异步系统的一种特例。

该模型便于设计算法，然后将其翻译成更实际的模型。

- Dijkstra E W. Co-operating Sequential Process. In programming Language. F. Genyus(ed.). [S.I.]: Academic Press, 1968, 43-112;
- Owicki S, Gries D. Verifying Properties of Parallel Programs: An Axiomatic Approach. Communication ACM 19, 5(1976), 279-285;

§ 1.3 理论和实际之关系

■ 错误的种类

❖ 初始死进程

指在局部算法中没有执行过一步。

❖ **Crash failure**崩溃错误(损毁模型)

指处理机没有任何警告而在某点上停止操作。

❖ **Byzantine failure**拜占庭错误

一个出错可引起任意的动作, 即执行了与局部算法不一致的任意步。拜占庭错误的进程发送的消息可能包含任意内容。

Ch.2 消息传递系统中的基本算法

本章介绍无故障的msg传递系统，考虑两个主要的计时模型：同步及异步。

定义主要的复杂性度量、描述伪代码约定，最后介绍几个简单算法

§ 2.1 消息传递系统的形式化模型

§ 2.1.1 系统

1.基本概念

■ 拓扑：无向图 结点——处理机
 边 ——双向信道

§ 2.1.1 系统

■ **算法：**由系统中每个处理器上的局部程序构成

❖ **局部程序** { 执行局部计算——本地机器
 { 发送和接收msg——邻居

❖ **形式地：**一个系统或一个算法是由 n 个处理器 p_0, p_1, \dots, p_{n-1} 构成，每个处理器 p_i 可以模型化为一个具有状态集 Q_i 的状态机（可能是无限的）

§ 2.1.1 系统


■ 状态（进程的局部状态）

由 p_i 的变量， p_i 的msgs构成。

p_i 的每个状态由 $2r$ 个msg集构成：

- ❖ $outbuf_i[l](1 \leq l \leq r)$: p_i 经第 l 条关联的信道发送给邻居，但尚未传到邻居的msg。
- ❖ $inbuf_i[l](1 \leq l \leq r)$: 在 p_i 的第 l 条信道上已传递到 p_i ，但尚未经 p_i 内部计算步骤处理的msg。

模拟在信道上传输的msgs



§ 2.1.1 系统

■ 初始状态:

- ❖ Q_i 包含一个特殊的初始状态子集: 每个 $\text{inbuf}_i[l]$ 必须为空, 但 $\text{outbuf}_i[l]$ 未必为空。

■ 转换函数(transition):

处理器 p_i 的转换函数(实际上是一个局部程序)

- ❖ **输入:** p_i 可访问的状态
- ❖ **输出:** 对每个信道 l , 至多产生一个 msg 输出
- ❖ 转换函数使输入缓冲区 ($1 \leq l \leq r$) 清空。

§ 2.1.1 系统

- **配置：**配置是分布式系统在某点上整个算法的全局状态

向量= $(q_0, q_1, \dots, q_{n-1})$, q_i 是 p_i 的一个状态

一个配置里的outbuf变量的状态表示在通信信道上传输的信息，由del事件模拟传输

一个初始的配置是向量= $(q_0, q_1, \dots, q_{n-1})$ ，其中每个 q_i 是 p_i 的初始状态，即每个处理器处于初始状态

§ 2.1.1 系统

- **事件：**系统里所发生的事情均被模型化为事件，对于msg传递系统，有两种：

comp(i)——计算事件。代表处理器 p_i 的一个计算步骤。其中， p_i 的转换函数被用于当前可访问状态

del(i,j,m)——传递事件，表示msg m从 p_i 传送到 p_j

- **执行：**系统在时间上的行为被模型化为一个执行。

它是一个由配置和事件交错的序列。该序列须满足各种条件，主要分为两类：

§ 2.1.1 系统

① Safety条件：（安全性）

表示某个性质在每次执行中每个可达的配置里都必须成立

在序列的每个有限前缀里必须成立的条件

例如：“在leader选举中，除了 p_{\max} 外，没有哪个结点宣称自己是leader”

非形式地：安全性条件陈述了“尚未发生坏的情况” “坏事从不发生”

§ 2.1.1 系统

② **liveness**条件：(活跃性)

表示某个性质在每次执行中的某些可达配置里必须成立。

必须成立一定次数的条件(可能是无数次)

例如：条件：“ p_1 最终须终止”，要求 p_1 的终止至少发生一次；“leader选举， p_{\max} 最终宣布自己是leader”

非形式地，一个活跃条件陈述：“最终某个好的情况发生”

对特定系统，满足所有要求的安全性条件的序列称为一个**执行**；
若一个执行也满足所有要求的活跃性条件，则称为**容许**(合法的)(admissible)**执行**