第二部分 分布式算法

第六次课

中国科学技术大学计算机系

国家高性能计算中心（合肥）

第4章

分布式系统中的计算模型

概述

- 分布式系统计算模型的复杂性
  - 系统由并发执行部件构成
  - 系统中无全局时钟
  - 必须捕捉系统部件可能的失效
- 对策
  - 因果关系（Causality）
  - 一致状态（Consistent states）
  - 全局状态

§4.1 基本知识

- 协议（Protocol）
- 协议中的控制语句

1.Send（destination, action; parameters）

destination：处理器抽象。实用中是通信实体的地址：机器名，机器的端口号(即1个socket地址)

action：控制msg，希望接收者采取的动作

parameters：参数集合

假定：

msg发送是无阻塞、可靠的（语义类似于TCP套接字）；

有时假定较弱的msg传递层（等价于UDP）。

TCP与UDP的区别：①基于连接与无连接②对系统资源的要求（TCP较多，UDP少）③UDP程序结构较简单④流模式与数据报模式

●TCP保证数据正确性，UDP可能丢包

●TCP保证数据顺序，UDP不保证

§4.1 基本知识

2.接收msg

接收msg可推广至接收事件，引起事件的原因是：

外部msg、超时设定、内部中断

事件在处理前，一般是在缓冲区(如事件队列)中，若一处理器想处理事件，它必须执行一个声明处理这些事件的线程。

例如，一个节点通过执行下述代码等待事件$A_1, A_2,..., A_n$

```
waiting for A1, A2,..., An ： //声明
   A1（Source; parameters）
       Code to handle  A1
   ….
   An（Source; parameters）
       Code to handle  An
```

当p执行send(q, A_1; parameters)且q执行上述代码时，q将最终处理由p发送的msg

§4.1 基本知识

3.超时

当怀疑远程处理器失效时，可通过超时检测来判定：

①当T秒后仍未收到P的类型为event的msg时，执行指定的动作

```
waiting until P sends (event; parameters), timeout=T
    on timeout
        timeout action
```

②仅当收到一个响应msg时才采取动作，超时不做任何动作

```
waiting until P sends (event; parameters), timeout=T
    on timeout;
if no timeout occurred
   { Successful response actions }
```

§4.1 基本知识

3.超时

③处理器等待响应T秒

若处理器在等待开始后T秒内没响应，则等待结束，协议继续

waiting up to T seconds for (event; parameters) msgs

Event: < msg handling code >

§4.2 因果关系

分布式系统为何缺乏全局的系统状态？

1.非即时通信

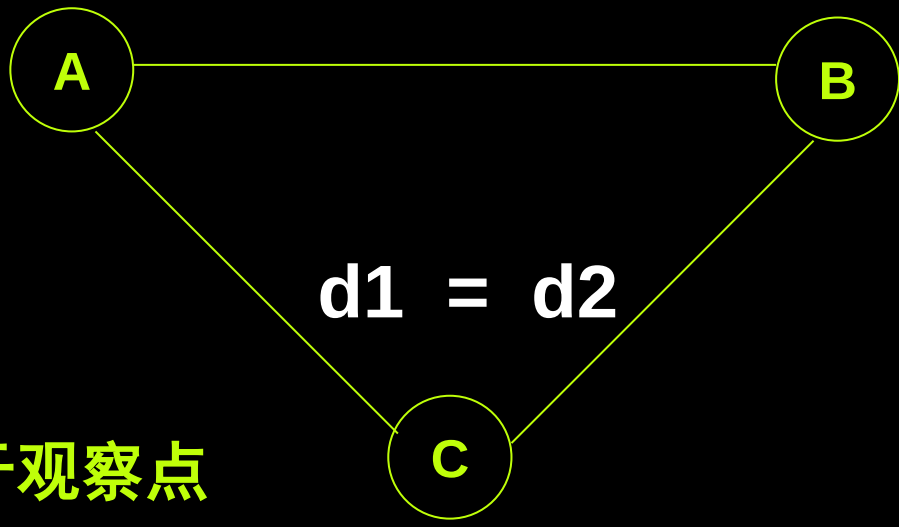

A和B同时向对方喊话

他们都认为是自己先喊话

C听到两人是同时喊话

结论：系统的全局状态依赖于观察点

原因：

- 传播延迟
- 网络资源的竞争
- 丢失msg重发

§4.2 因果关系

2.相对性影响

假设张三和李四决定使用同步时钟来观察全局状态：

他们约定下午5点在某餐馆会面，张三准时到达，但李四在一个接近光速的日光系统中游览。

张三在等待李四1小时后离开餐馆，而李四在自己的表到达5点时准时达到餐馆，但他认为张三未达到。

因为大多数计算机的实际时钟均存在漂移，故相对速度不同，时钟同步仍然是一个问题。

结论：使用时间来同步不是一个可靠机制。

§4.2 因果关系

3.中断

假设张三和李四在同一起跑线上赛跑，信号为小旗，前两个问题可以忽略，但是...

即使可忽略其他影响，也不可能指望不同的机器会同时做出某些反应。因为现代计算机是一个很复杂的系统：CPU竞争、中断、页错误等，执行时间无法预料。

结论：不可能在同一时刻观察一个分布式系统的全局状态

必须找到某种可以依赖的性质：

- 时间回溯
- 因果相关

§4.2 因果关系

- **假设分布式系统构成：**

  $P=\{P_1, P_2, \ldots, P_n\}$：处理器集合

  $\mathcal{E}$：全体事件的集合

  $\mathcal{E}_p \subseteq \mathcal{E}$，$\mathcal{E}_p$表示发生在p上的所有事件

- **次序** $e_1 < e_2$：事件e_1发生e_2在之前（亦记：$e_1 \rightarrow e_2$）

  $e_1 <_I e_2$：事件e_1发生e_2在之前，I为信息源

- **定序** **有些$\mathcal{E}$中事件很容易定序：**

  - 发生在同一节点p上的事件满足全序：

    若$e_1, e_2 \in \mathcal{E}_p$，则 $e_1 <_p e_2$ 或 $e_2 <_p e_1$ 成立

  - e_1发送消息m，e_2接收m，则$e_1 <_m e_2$

§4.2 因果关系

■ Happens-before关系（$<_H$）

该关系是节点次序和消息传递次序的传递闭包：

- ❖规则1：若$e_1 <_p e_2$，则$e_1 <_H e_2$
- ❖规则2：若$e_1 <_m e_2$，则$e_1 <_H e_2$
- ❖规则3：若$e_1 <_H e_2$，且$e_2 <_H e_3$，则$e_1 <_H e_3$

在集合 X 上的二元关系 R 的传递闭包是包含 R 的 X 上的最小的传递关系。

$e_1 <_H e_3$表示存在1个事件因果链，使e_1发生e_3在之前

Note：$<_H$是一种偏序关系，即

存在e和e’，二者之间无这种关系

- ❖并发事件：若两事件不能由$<_H$定序

§4.2 因果关系

Happens-before关系（$<_H$）

- 规则1表述的是同一处理器上两个事件之间的因果关系；
- 规则2表述了不同处理器上两个事件之间的因果关系
- 规则3阐述了传递律

Note:

Happens-Before关系完整表述了执行中的因果关系。如果一个执行中的事件按照其相对顺序重新进行排序，而不改变他们的happens-before关系的话，那么其结果仍是一个执行，并且对处理器而言，该执行与原执行并无区别。

§4.2 因果关系

■ 举例

1) 因事件e1, e4和e7均发生在P1上，故：$e_1 <_{P1} e_4 <_{P1} e_7$

2) 因e1发送1个msg到e3，故：$e_1 <_m e_3$，类似地$e_5 <_m e_8$

3) 应用规则1和2得：

$e_1 <_H e_4 <_H e_7$，$e_1 <_H e_3$，$e_5 <_H e_8$

4) 由$<_H$的传递闭包性质得：

$e_1 <_H e_8$

5) e1和e6是并发的：e1和e6之间无路径

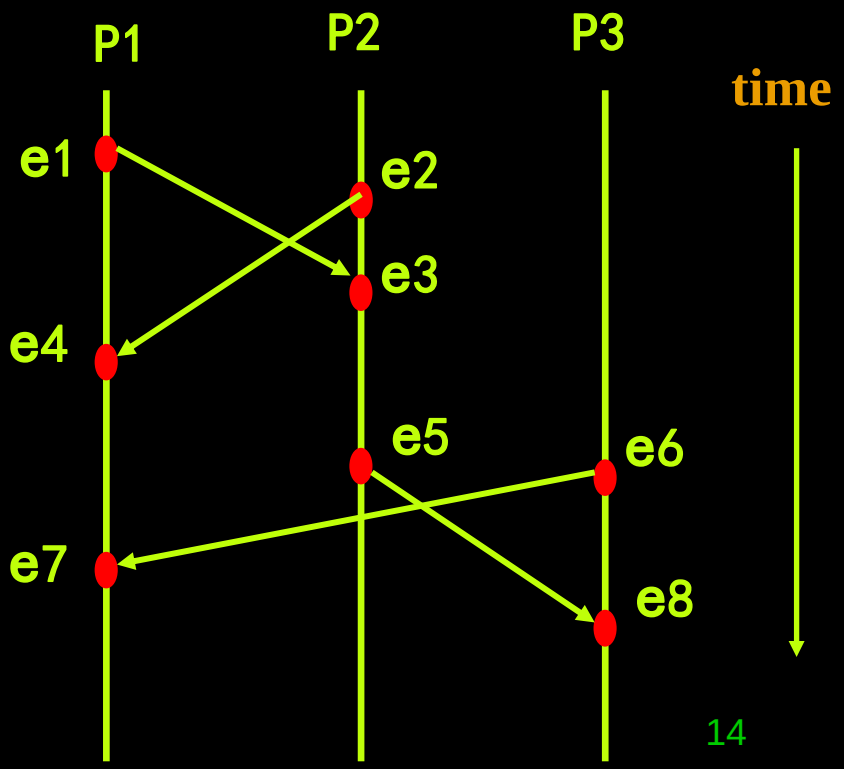

§4.2 因果关系

H－DAG

有时将Happens-before关系描述为一个有向无环图

- 顶点集V_H是事件集$\mathcal{E}$：$e \in V_H$ 当且仅当 $e \in \mathcal{E}$
- 边集E_H：若$(e_1, e_2) \in E_H$ 当且仅当$e_1 <_P e_2$或$e_1 <_m e_2$

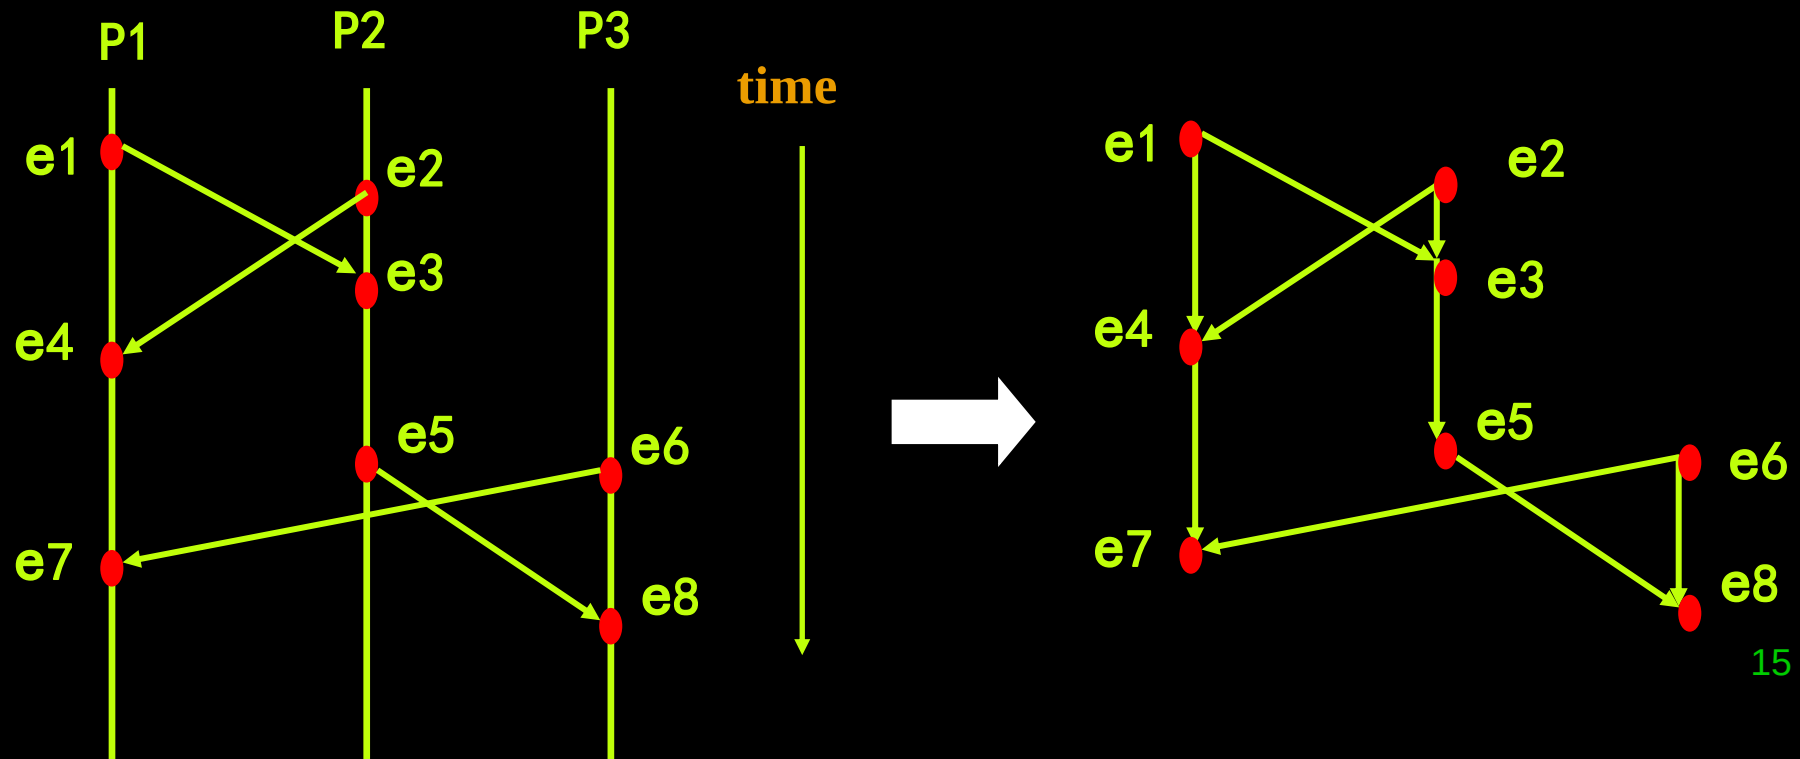

§4.2.1 Lamport时间戳

- 系统有序性的重要性

  若分布式系统中存在全局时钟，则系统中的事件均可安排为全序。例如，可以更公平地分配系统资源。

- 全序对事件的影响和由H关系确定的偏序对事件的影响是一致的

- 如何通过H关系确定的偏序关系来建立一个“一致”的全序关系？

  - 在$<_H$的DAG上拓扑排序
  - On the fly：Lamport提出了动态即时地建立全序算法

§4.2.1 Lamport时间戳

- **Lamport算法的思想**

  每个事件e有一个附加的时戳：e.TS

  每个节点有一个局部时戳：my_TS

  每个msg有一个附加时间戳：m.TS

  节点执行一个事件时，将自己的时戳赋给该事件；

  节点发送msg时，将自己的时戳赋给所有发送的msg。

§4.2.1 Lamport时间戳

- **Lamport算法的实现**

```
Initially： my_TS=0;
On event e：
    if （ e是接收消息m ) then
        my_TS = max ( m.TS, my_TS );
        //取msg时戳和节点时戳的较大者作为新时戳
    my_TS++;
    e.TS＝my_TS; //给事件e打时戳
    if ( e是发送消息m ) then
        m.TS＝my_TS; //给消息m打时戳
```

§4.2.1 Lamport时间戳

- **Lamport算法赋值的时戳是因果相关的**

  若$e_1 <_H e_2$，则 $e_1.TS < e_2.TS$

  ∵若$e_1 <_P e_2$或$e_1 <_m e_2$，则的e_2时戳大于e_1的时戳

  ∴在因果事件链上，每一事件的时戳大于其前驱事件的时戳

- **问题：系统中所有事件已为全序？**

  不同的事件可能有相同的时戳（并发事件）

- **Lamport算法改进**

  因为并发事件的时戳可以任意指定先后

  故可用节点地址作为时戳的低位

§4.2.1 Lamport时间戳

改进的Lamport时戳

事件标号：时戳.id

事件e8为4.3:

my_TS=max(m.TS,my_TS)

=max(3,1)=3

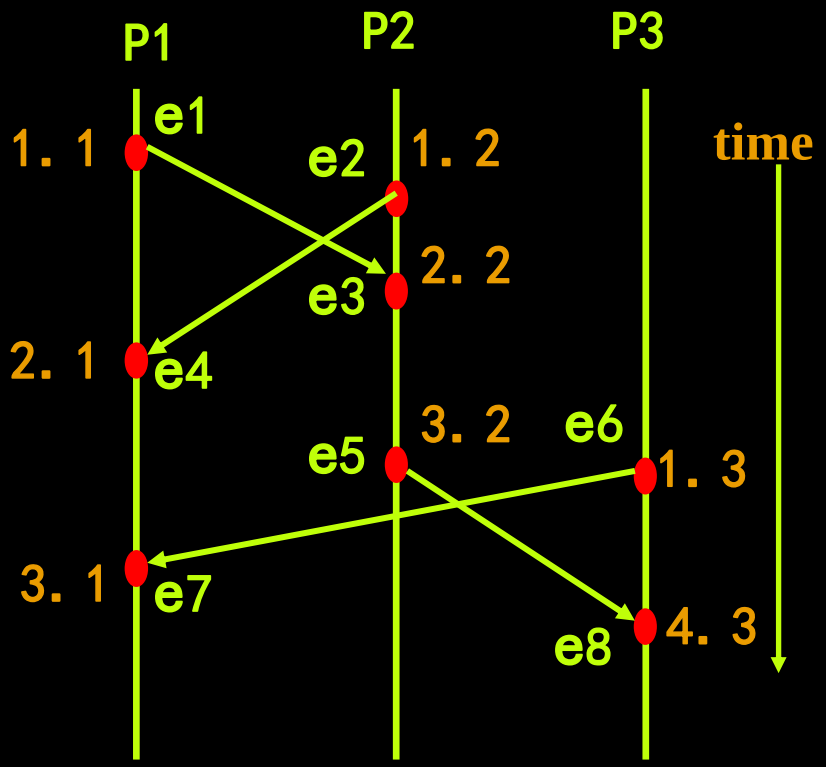

按字典序得全序：

1.1，1.2，1.3，2.1，2.2，3.1，3.2，4.3

算法特点：分布、容错、系统开销小

- Lamport算法的迷人之处在于：任何进程在发送消息前，先将自己的本地计数器累加1；接收进程总是计算自己的本地计数器和接受到计数器中较大值加上1的结果

§ 4.2.2 向量时间戳

- **Lamport时戳缺点**

若$e_1 <_H e_2$，则 $e_1.TS < e_2.TS$；反之不然。

例如：1.3<2.1，但是$e_6 < e_4$不成立

原因：并发事件之间的次序是任意的

不能通过事件的**时戳判定**两事件之间是否是**因果相关**

- **判定事件间因果关系的重要性**

例子：违反因果关系检测

在一个分布式对象系统中，为了负载平衡，对象是可移动的，对象在处理器之间迁移是为了获得所需的调用的进程或资源。如下图：

§4.2.2 向量时戳

1)P1持有对象O，决定迁移到P2

为获取资源，P1将O装配在消息M1中发送给P2

2)P1收到P3访问O的请求

P1将O的新地址P2放在消息M2中通知P3

3)P3在M3中请求访问P2的O

当M3达到P2时，O不可用，故回答一个出错消息。

- 问题：当debug该系统时，会发现O已在P2上，故不知错在哪？

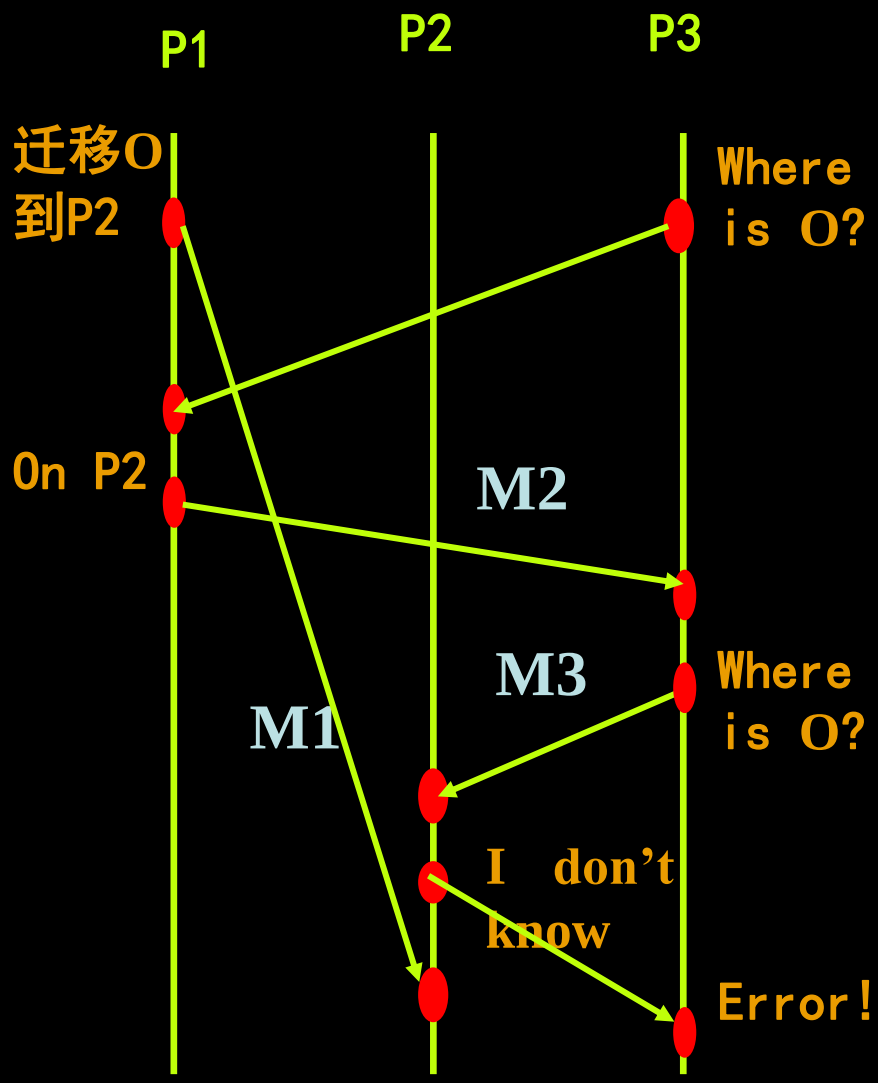

§ 4.2.2 向量时间戳

- **错误原因：违反因果序**

P3请求O是发生在从P1迁移到P2之后，但该请求被处理是在迁移达到P2之前。形式地，

设：s(m)是发送m的事件

r(m)是接收m的事件

若$s(m1) <_H s(m2)$，则称消息m1因果关系上先于m2，记做$m1 <_C m2$

若$m1 <_C m2$，但 $r(m2) <_P r(m1)$，则违反“因果关系”：

即，若m1先于m2发送，但在同一节点P上m2在m1之前被接收

例如，在上例中有：

$M1 <_C M3$，但 $r(M3) <_{P2} r(M1)$

§4.2.2 向量时间戳

违反因果序检测

- 定义：若时戳VT具有比较函数$<_V$满足：

  $e1 <_H e2$ iff $e1.VT <_V e2.VT$

  则我们能够检测出是否违反因果关系

- VT性质

  1）因$<_H$是偏序，故$<_V$也是偏序；

  2）因为必须知道在因果关系上每一节点中哪些事件是在事件e之前，故e.VT中必须包含系统中每一个其它节点的状态。

  这两个性质导致了向量时戳VT的引入

§4.2.2 向量时戳

向量时戳VT

VT是一个整数数组：

e.VT[i]=k表示在节点i（或P_i）上，因果关系上e之前有k个事件（可能包括e自己）。

e.VT=(3,6,4,2)表示因果序：

在P1上，有3个事件须在e之前

在P2上，有6个事件须在e之前

在P3上，有4个事件须在e之前

在P4上，有2个事件须在e之前

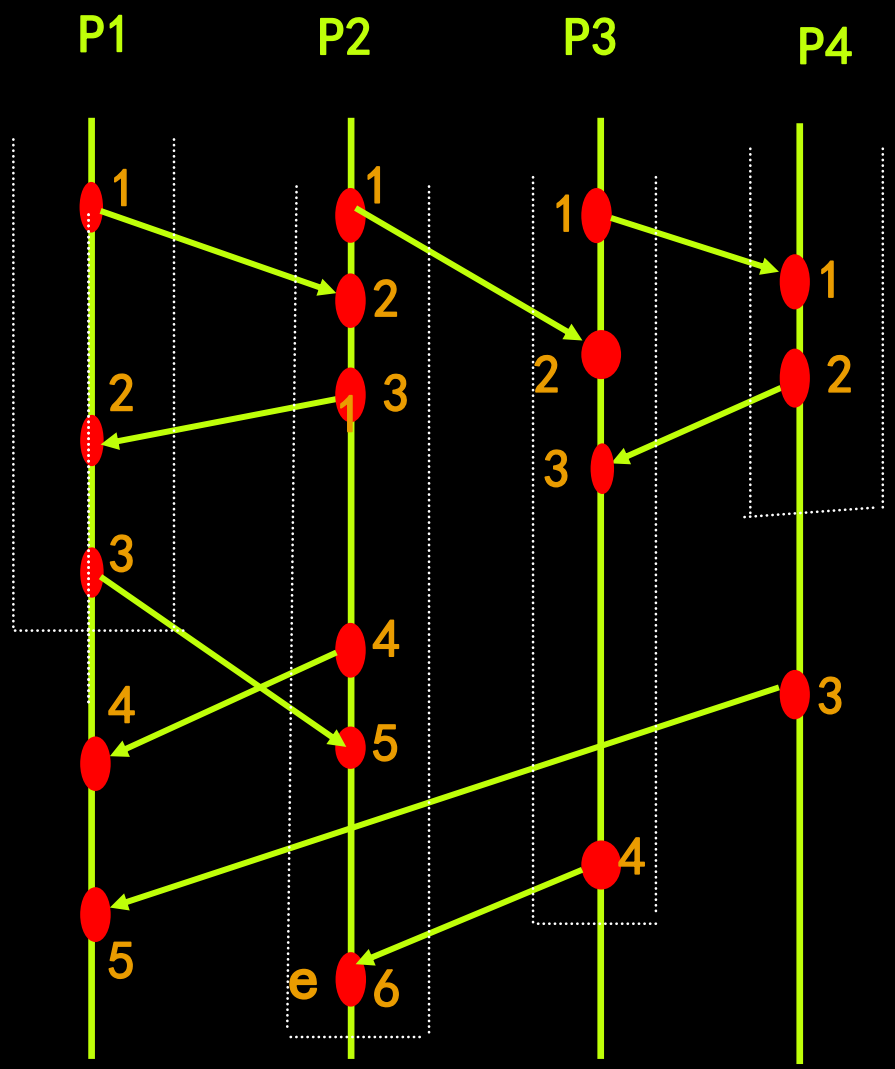

§4.2.2 向量时间戳

向量时戳的意义

在因果关系上，e1.VT $\leqslant_V$ e2.VT表示e2发生在e1及e1前所有的事件之后。更精确的说，向量时钟的次序为：

e1.VT$\leqslant_V$ e2.VT iff e1.VT[i]$\leqslant$ e2.VT[i], i=1, 2, …, M

e1.VT$<_V$ e2.VT iff e1.VT$\leqslant_{VT}$e2.VT且e1.VT$\neq$e2.VT

向量时戳算法

my_VT：每个节点有局部的向量时戳

e.VT：每个事件有向量时戳

m.VT：每个msg有向量时戳

节点执行一个事件时，将自己的时戳赋给该事件；

节点发送msg时，将自己的时戳赋给所有发送的msg。

注意$\leq_V$, $\leq_{VT}$以及$<_V$之间的区别：V代表因果序，而VT代表时戳比较

§ 4.2.2 向量时间戳

- 算法实现

Initially： my_VT=[0,…,0];

On event e：

```
if （e是消息m的接收者）then
    for i=1 to M do //向量时戳的每个分量只增不减
        my_VT[ i ] = max( m.VT[i], my_VT[i] );
my_VT[ self ]++; //设变量self是本节点的名字
e.VT＝my_VT; //给事件e打时戳
if ( e是消息m的发送者 ) then
    m.VT＝my_VT; //给消息m打时戳
```

§4.2.2 向量时间戳

- **算法性质**

1）若$e <_H e'$，则$e.VT <_{VT} e'.VT$

∵算法确保对于每个事件满足：

若$e <_P e'$或$e <_m e'$，则$e.VT <_{VT} e'.VT$

2）若$e \not<_H e'$，则$e.VT \not<_{VT} e'.VT$

pf：若e和e' 因果相关，则有$e' <_H e$，即$e'.VT <_{VT} e.VT$

若e和e‘ 是并发的，则在H-DAG上，从e到e’和从e’到e均无有向路径，即得：

$e.VT \not<_{VT} e'.VT$ 且 $e'.VT \not<_{VT} e.VT$

当且仅当e.VT和e’.VT是不可比时，称向量时戳是捕获并发的！

§4.2.2 向量时戳

向量时戳比较

e1.VT=(5,4,1,3)

e2.VT=(3,6,4,2)

e3.VT=(0,0,1,3)

1）e1和e2是并发的

∵e1.VT[1]>e2.VT[1]

e1.VT[2]<e2.VT[2]

∴e1到e2及e2到e1均无路径

2）e3在因果序上先于e1

即：e3. VT$<_V$ e1. VT

e1的前驱事件见方框

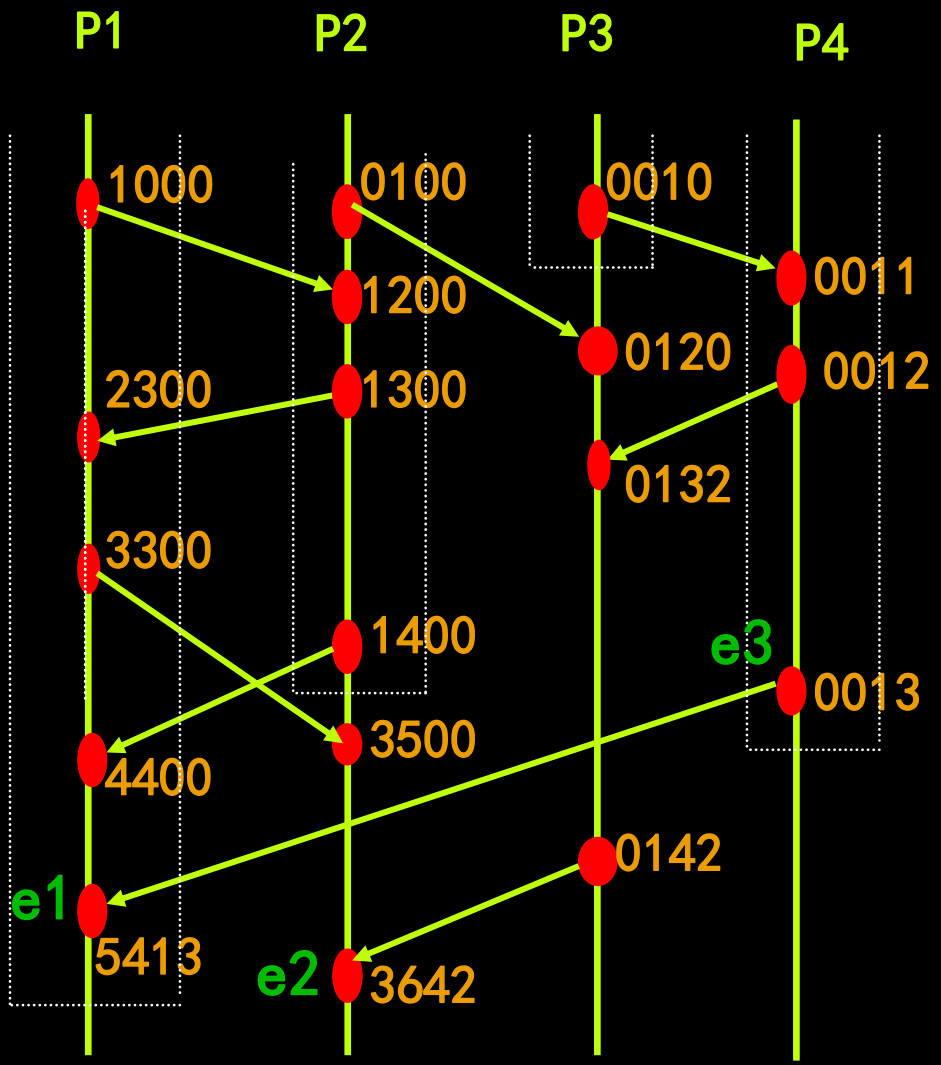

§4.2.2 向量时戳

因果序检测

1）消息时戳间比较

在P2上，先到达的M3的时戳为（3,0,3），后到达的M1的时戳为（1,0,0）。但是：

∵ $(1,0,0) <_V (3,0,3)$

∴ M1在因果序上先于M3

故M1后于M3到达违反因果序

2）消息时戳和局部时戳比较

当时戳为(1,0,0) 的M1到达P2时，P2的时戳是(3,2,3)。但：

∵ $(1,0,0) <_V (3,2,3)$

∴ M1在因果序上应先于(3,2,3)对应的事件

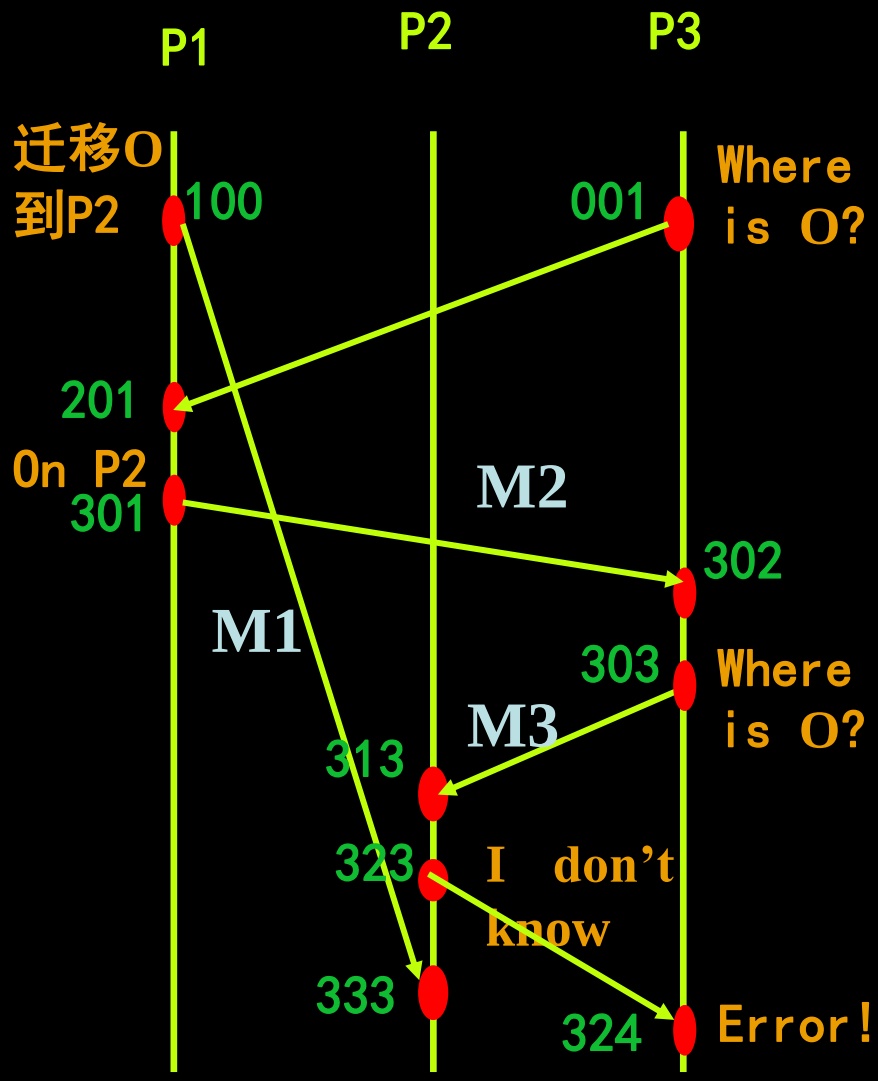

§4.2.3 因果通信

- 如何保证通信不违反因果关系？

  处理器不能选择msg达到的次序，但能抑制过早达到的msg来修正传递（指提交给应用）次序。

- FIFO通信（如TCP）

  由msg传递协议栈里的一层负责确保FIFO通信

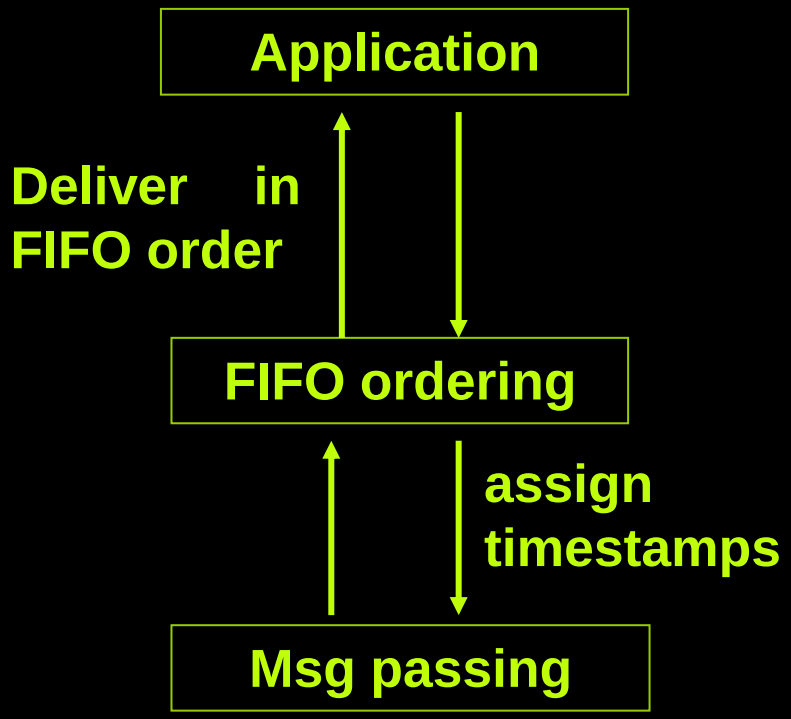

§4.2.3 因果通信

FIFO通信

源处理器给每个发送的msg顺序编号，目的处理器知道自己所收到的msg应该有何顺序的编号，若目的处理器收到一个编号为x的msg但未收到较小编号的msg时，则延迟传递直至能够顺序传递为止。

因果通信

因果通信与FIFO通信类似

源：附上时戳

目的地：延迟错序msg

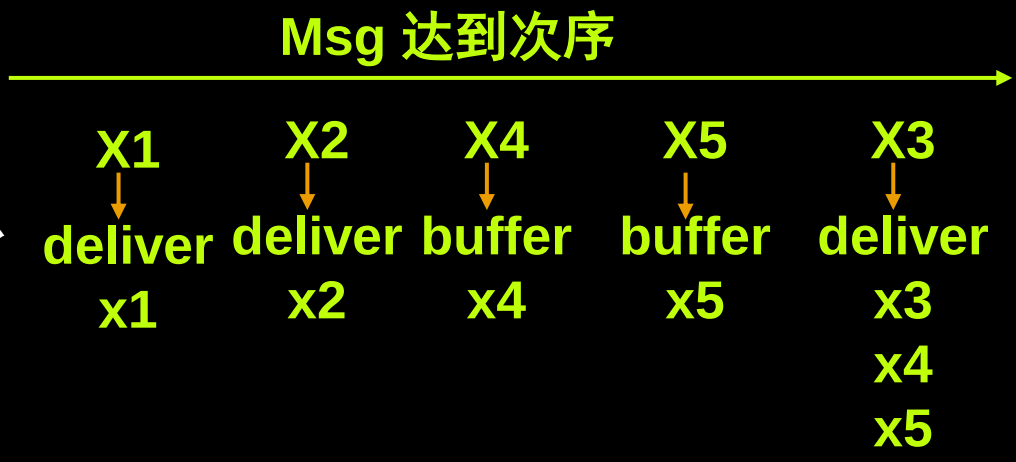

§4.2.3 因果通信

因果通信实现思想

- 抑制从P发送的消息m，直至可断定没有来自于其它处理器上的消息m’，使m’ $<_V$ m.
- 在每个节点P上：

earliest[1..M]：存储不同节点当前能够传递的消息时戳的下界

earliest[k]表示在P上，对节点k能够传递的msg的时戳的下界

blocked[1..M]：阻塞队列数组，每个分量是一个队列

Alg. Causal Msg delivery

定义时戳1_k： 若使用Lamport时戳，则1_k＝1；

若用向量时戳，则1_k＝(0,…,1,0,…,0)，k^{th}位为1

初始化

1: earliest[k] =1_k， k=1,…,M

2: blocked[k] ={ }， k=1,…,M//每个阻塞队列置空

§4.2.3 因果通信

3:On the receipt of msg m from node p:
4: delivery_list={};
5: if （blocked[p]为空）then
6: earliest[p]=m.timestamp;
7: 将m加到blocked[p]队尾；//处理收到的消息
8: while（∃k使blocked[k]非空 and 对每个i=1,…,M(除k和self外),
not_earliest(earliest[i], earliest[k], i)） {//处理阻塞队列
//对非空队列k，若其他节点i上无比节点k更早的msg要达到本
//地，则队列k的队首可解除阻塞
9: 将blocked[k]队头元素m’出队，且加入到delivery_list;
10: if （blocked[k]非空）then
11: 将earliest[k]置为m’.timestamp；
12: else increment earliest[k] by 1_k }//end while
13: deliver the msgs in delivery_list; //按因果序

§4.2.3 因果通信

向量时戳比较

（ not_earliest(earliest[i], earliest[k], i)）

not_earliest(proc_i_vts, msg_vts, i) {//前者不早于后者时为真

if （ msg_vts[i]<proc_i_vts[i] ）（其他节点i的earliest[i]不比k早，即不比k的时间戳小）

return ture;

else return false;

}

分析

使用向量时戳较好，不会假定序。

1）初始化：在本地节点（self）上，能够最早传递的来自于节点k的msg的时戳存储在本地的earliest[k]中，line1初始化正确

2）处理接收的消息：当本地节点接收来自于p的消息m时

行5,6：若blocked[p]中无msg，则earliest[p]被置为m的时戳，

§4.2.3 因果通信

分析

行7：将m放入阻塞队列blocked[p]中，直到可安全传送为止。

3）处理阻塞：因m的达到能够将earliest[p]中的时戳更新（变大），故可能会使若干个阻塞的msg变为非阻塞；当然m本身可能是安全的，可直接传递给应用。

最终，一个阻塞msg变为非阻塞msg后，也可能使其他阻塞msg变为非阻塞msg。

行8：while循环检查阻塞队列，对于非空队列k进行处理。

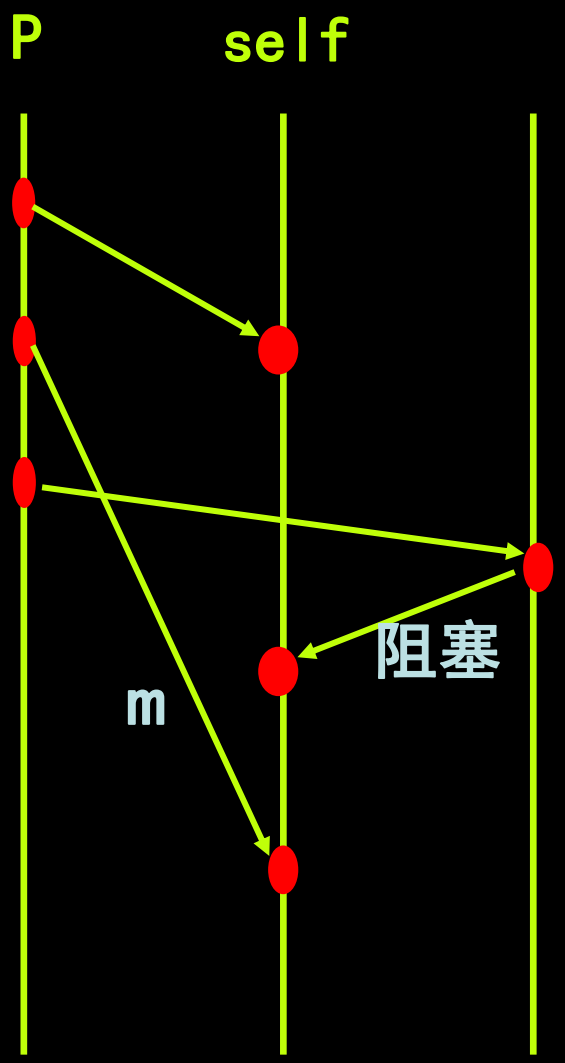

§4.2.3 因果通信

分析

什么样的msg是非阻塞的？

当阻塞队列k（指blocked[k]）非空时，检测其能否解除阻塞：

设队头msg是m，在self上若其他节点i（除self和k之外）无更早时戳earliest[i](即比m.timestamp=earliest[k]更小)的msg可能被传递，则消息m是非阻塞的。此时，m可安全传递，m出队（行9）。

4）问题

上述算法可能会发生死锁：若一节点长时间不发送你要的msg，会发生死锁。

因此，上述因果通信算法通常被用于组播的一部分。

§4.2.3 因果通信

算法执行例子（Causal Multicast）

因为协议只对发送事件的因果序感兴趣，故一节点只有发送msg时对向量时戳做增量操作。

①处理接收消息：当p3从p1接收m2时，修改earliest[1]为(1,1,0)，m2入阻塞队列blocked[1]；//line6，7

②处理阻塞：blocked[1]≠Φ，故while循环中k=1，self=3，i=2，not_earliest(earliest[2], earliest[1], 2)，前者早于后者，表示p2上有一个更早的msg还没有达到p3，返回假。m2被阻塞

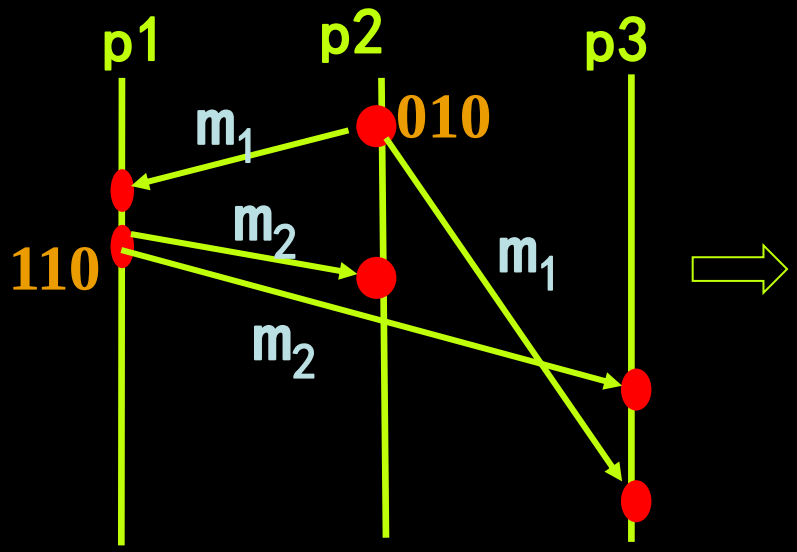

在p3上

earliest[1]	earliest[2]	earliest[3]
(1,0,0)	(0,1,0)	(0,0,1)

接收m2　//k=1, i=2, 阻塞m2

m2		
（1,1,0） ≥	(0,1,0)	(0,0,1)

§4.2.3 因果通信

①处理接收消息：当p3从p2接收m1时，earliest[2]为(0,1,0)(不变)，m1入阻塞队列blocked[2]；//line6，7

②处理阻塞：while检测各阻塞队列是否有阻塞的msg。

k=2, blocked[2]≠Φ，其中的m1不依赖其他事件，故放入传递表（行9），m1出队后blocked[2]=Φ，earliest[2][2]+1(行12)后earliest[2] =(0,2,0);

k=1,blocked[1]≠Φ，self=3，i=2，not_earliest(earliest[2]，earliest[1]，2)，前者不早于后者，表示p2上无更早的msg会达到p3，返回真。m2从blocked[1]出队入传递表(行9)，blocked[1]=Φ，earliest[1][1]+1(行12)后earliest[1]=(2,1,0)。

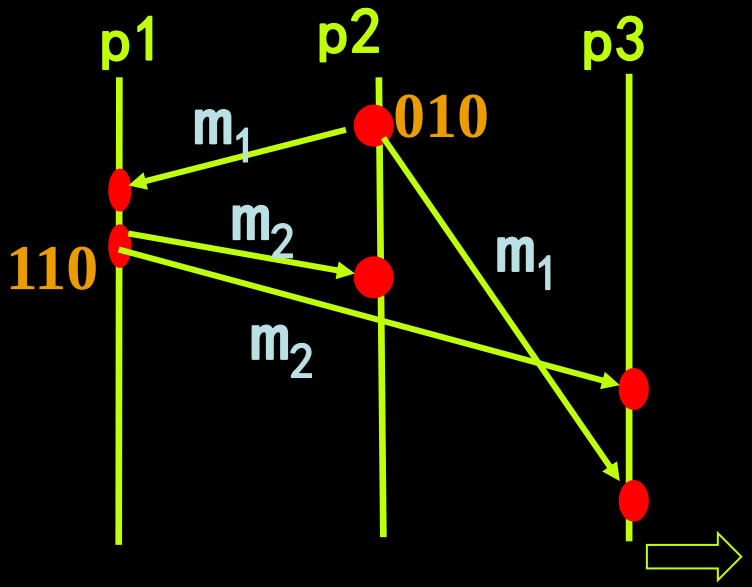

earliest[1]　earliest[2]

接收m1

m2	m1	//k=2, i=1
（1,1,0） >	(0,1,0)	(0,0,1)
deliver m1		
m2		//k=1, i=2
（1,1,0） <	(0,2,0)	(0,0,1)
deliver m2		
（2,1,0）	(0,2,0)	(0,0,1)